HY5419 · Seminar 4

文本语料库、数字档案与 文本分析工作坊

课程重点、内容梳理与后续思考笔记

一句话总括

数字史研究不是按下按钮就得到答案，而是把研究问题、语料库、档案生产链、清洗、分析、解释与反思串成一个可追溯、可复现、会迭代的过程。

课程日期：2026 年 9 月 1 日

素材：课堂录音（约 2:14:35）与有道听课宝转写 PDF

本笔记已将转写中的明显识别错误按课堂语境规范化；涉及原声复核时，请以音频为准。

一、课程地图：今天到底学了什么

课堂先回接上周关于公共史、社区研究与研究伦理的讨论，再转入“文本如何被做成可搜索的数据”，由 Gale 讲解数字档案生产与 OCR，最后进入 Digital Scholar Lab 的操作练习。

时间点（录音）	课堂段落	回顾时要抓住的关键词
00:33–12:02	上周问题回顾与研究伦理	开放获取、社区合作、补偿、风险、AI 与专家协作
12:02–30:00	进入本周主题：语料库与项目设计	语料库结构、关键词、异质数据、范围、文档化
30:34–1:25:11	Chris（Gale）数字档案幕后讲解	编辑选择、商业案例、扫描、元数据、OCR、维护
1:25:22–1:45:42	文本与数据挖掘、实验心态	n-gram、主题建模、探索与推断、迭代、反思
1:47:00–2:04:17	Digital Scholar Lab 动手练习	Build–Clean–Analyze、内容集、清洗配置、分类主题
2:04:27–2:14:28	总结与下周预告	工具不是答案；人文学者负责问题、语境与解释；下周空间数据

建议的三遍回顾法

第一遍只看本笔记的“主张”；第二遍按时间点回听，补上讲者的例子；第三遍把“研究日志模板”用于自己的项目，写出一个可执行的小实验。

六个最需要带走的结论

- 数字化不是中性的搬运：选什么、删什么、怎样命名和怎样呈现，都会改变研究者能看到的问题。
- 语料库的来源、结构、缺失与编辑历史，决定了数据可以支持什么结论；不理解语料库，就无法恰当地解释结果。
- OCR 让档案可搜索，但它是概率性的机器读取，不是原文的完美替身；搜索不到不等于文本中不存在。
- 文本分析适合先探索“数据的轮廓”，再回到原始图像和细读，最后才形成有证据边界的论证。
- Build–Clean–Analyze 不是直线流程，而是循环：一次只改少量变量，记录改变，再运行、比较和反思。
- 工具不会自动产生历史意义；研究问题、语境化、伦理判断与解释仍然是人文学者的工作。

二、研究伦理：开放、合作与“不要把人当成资料”

开场回顾把数字史研究放回更大的制度环境：知识和教育常被当成商品，研究评价又受资金、影响力和机构结构影响。课程并不假装一次课能解决这些结构性问题，但要求研究者看见它们，并在项目设计中作出负责任的选择。

课堂要点

- 公共史与开放获取的目标，不只是把成果放到网上，而是让合作社区和更广泛公众能够接触、参与并从研究中受益。
- 社区研究应从“与人一起研究”出发，而不是“在别人身上取材”。社区成员不欠研究者他们的故事、知识或经历，尤其是仍在世的人。
- 补偿要询问对方认为什么有意义：可以是报酬、交通与时间补偿，也可以是仪式性礼物、建议、持续投入或建立关系的时间；应在经费申请阶段列入预算。
- 开放获取有不同层级：公开、限制访问、延迟开放（embargo），甚至不公开数据或成果，都可能是合乎伦理的选项。关键是尽早与社区共同决定。
- 研究极化或仇恨团体时，要审查对方为何参与、他们想获得什么，以及研究是否会无意中为其观点背书或提供合法性；同时要安排研究者的心理安全与支持资源。
- AI 和代码工具可用于早期探索可行性，却不能替代对研究问题、代码逻辑、证据语境和偏差的理解。需要与计算机科学家从项目初期形成公平的“贸易区”式合作。

伦理决策的最早节点

不要等到论文写完才问“能不能发布”。从招募、取样、数据结构设计开始，就写下谁能访问、哪些字段需要遮蔽、谁拥有撤回权，以及研究结果如何回馈社区。

回顾问题

问自己	写下一个具体回答
我的数据中有哪些活着的个人、社区或脆弱群体？	
他们对“有价值的回馈”如何定义？我是否真正问过？	
如果公开会造成伤害，限制、延迟或不公开的理由是什么？	
我的分析是否可能被参与者用来合法化有害主张？	

三、先理解语料库，再按下分析按钮

语料库不是自然存在的“过去本身”，而是由收藏、选择、数字化、命名、切分、OCR、元数据和平台界面共同制造的研究对象。课堂反复追问：哪些东西被纳入？哪些被留下？哪些语境被移除了？

搜索与语境

- 先做近距离阅读，了解来源的年代、体裁、作者、受众和术语习惯，再设计关键词。用今天的概念或拼写去搜历史文本，可能得到零结果。
- 为拼写变体、旧称、缩写、不同语言和词形建立词表；同时记录哪些变体被合并、哪些被保留。
- 搜索结果只反映“被 OCR 正确识别、被平台索引、并且用你的词命中”的部分，不等于完整的历史分布。
- 不同来源的扫描质量、DPI、版式、语言与 OCR 水平可能不同。跨语料库比较前，先问：项目成功的最低数据质量是什么？

项目范围与数据文档

层级	要问的问题	例子
必须有（must）	没有它，项目是否无法回答问题？	核心年份、关键来源、最基本的 OCR 质量
应该有（should）	有它会让结论更稳健吗？	另一种来源、可比的元数据、人工抽查
可以有（could）	如果时间和预算允许，什么会提升解释力？	额外可视化、扩展样本、定制代码
暂不做（won’t）	什么超出范围或无法可靠完成？	无法验证的超大规模推断

文档化不是行政负担，而是方法论的一部分

记录每一次删选、改名、纠错、参数变化和解释决定。一个星期后你会忘记为什么这样做；更重要的是，没有这些记录，别人无法判断数据是否适合复用，也无法复现你的结果。

最小数据文档模板

字段	应记录什么
来源与范围	收藏名称、来源机构、时间范围、文献类型、纳入/排除规则
数据处理	下载日期、文件格式、OCR 版本、清洗规则、拼写变体处理
分析设置	工具、参数、停用词表、运行日期、输出文件名
解释与限制	观察到什么、没有看到什么、可能的替代解释与下一步

四、数字档案的幕后：从收藏到可搜索文本

Chris 的核心教学目标，是让使用者知道数字档案并非“透明窗口”。Gale 以商业出版者身份与世界各地档案馆、图书馆和数字化供应商合作；平台上的每一层都包含技术、编辑、商业和制度选择。

阶段	做什么	研究者需要追问
1. 编辑构想	根据学科趋势、课程、研究需求和市场判断主题与收藏。	谁决定值得数字化？哪些主题被预先想象？
2. 商业案例	估算保存、设备、人工、转换和平台维护成本，决定是否投资。	商业可行性是否造成了资料偏向？
3. 谈判与权利	与来源馆协商数字化许可、收益分成、版权和服务责任。	图像知识产权、平台销售权和访问权分别属于谁？
4. 扫描成像	使用高质量设备逐页拍摄；珍贵或脆弱材料可用真空翻页设备。	装订、变形、褪色、裁切是否改变了可读性？
5. 预生产与元数据	补充标题、作者、日期、出版物、馆藏关系等，使内容可发现、可交叉搜索。	哪些字段是通用的？哪些是针对某种文献定制的？
6. 转换与 OCR	把数字图像转换成机器可读文本，支撑全文搜索和文本挖掘。	哪些字符、版式和语言可能被误读或漏读？
7. QA、维护与反馈	抽样检查、修正高频元数据，更新数据库、界面并观察使用情况。	使用数据如何反过来决定下一批数字化内容？

规模感

课堂给出的数量级提醒是：小型馆藏可能有 35–40 万页，中型约 100–150 万页，大型可达 400–600 万页；Gale 的跨馆藏资源覆盖约九个世纪、六大洲。正因规模巨大，很多质量控制采用抽样而不是逐页人工校正。

可用性也会塑造研究方向

平台会根据搜索频率、课程和市场需求决定维护或新增内容；因此“什么能被搜到”会反过来推动研究兴趣。使用平台时既要利用其便利，也要意识到供应商、馆藏选择和界面正在参与知识生产。

五、OCR：搜索入口，也是误差入口

OCR（optical character recognition，光学字符识别）通过识别页面上的线条、形状与上下文，把扫描图像转换成机器可读文本。它让研究者可以从实体档案的“逐页翻找”转向全文搜索，但它仍是概率性识别。

课堂示范的关键认识

- OCR 对水平、清晰、规则的印刷体最有把握；装订边弯曲、页面倾斜、褪色、污损、复杂版式、旧字体和多栏排版都会降低准确度。
- 讲者给出的当代大规模 OCR 经验范围约为 85%–95%（按馆藏而异，来自抽样估计）。这意味着仍可能有相当数量的字符、词和整段文本被误读。
- 标题、作者、日期、出版物等高频元数据通常会投入额外人工核查；正文则不可能在数百万页规模上逐页纠正。
- 搜索不到一个词，可能是关键词错了，也可能是拼写变体、OCR 错误或索引缺失。搜索结果需要回到页面图像核对。

当你看到……	不要直接推断……	应当做……
结果为零	文本里不存在	换旧称、拼写变体、邻近词；检查原图和上下文
词频异常高	主题真的如此重要	排查页眉、脚注、模板词、OCR 重复与文献类型偏差
乱码或奇怪符号	数据没有价值	定位扫描/版式原因，记录清洗规则，保留原始文本
可视化很漂亮	论证已经成立	抽取样本做细读，说明方法、误差与替代解释

研究者的 OCR 三步核查

① 用多种关键词与变体检索；② 回看原始图像和前后段落；③ 在研究日志中记录 OCR 限制、人工修正和未解决的不确定性。

六、文本与数据挖掘：从探索到有边界的推断

课堂示例从数字档案下载 PDF、图像或原始 OCR 文本，再用 Voyant Tools（转写中听作“Buoyant”）等免费工具生成词频统计和可视化。文本可以来自十八世纪法令，也可以来自推文；只要能表达为文本，就能被组合、比较和分析。

工具的角色

工具/方法	它擅长回答什么	不能单独回答什么
词频与 n-gram	哪些词或词组最常出现？哪些搭配值得追踪？	某个词为何出现、谁在说、语境和权力关系是什么？
词云/统计可视化	快速获得文本的轮廓和比较线索。	视觉大小不是历史重要性的直接证明。
主题建模	数据中可能存在哪些主题簇或结构？	主题标签不是机器自动给出的历史概念，需要人来命名、核查和解释。
情感/邻近词分析	某关键词附近的评价词和倾向如何变化？	词典、语料、体裁和时代语义会影响“正/负面”判断。
细读与跨语料比较	验证模式、理解例外，并在来源之间作可比比较。	不能把不同 OCR 质量、体裁和取样方式的数据当成完全同质。

课堂示例与方法边界

- 1930 年代关于计划生育的广播谈话：词频很快提示“出生控制、儿童健康、家庭、母亲”等方向，随后仍需回到原始文档做验证。
- 妇女参政主题的报纸社论：以 suffragette / suffragism / suffragist 等变体检索，再观察邻近词，发现“militant、opposing、outrage、conspiracy”等负面词群；这提示舆论框架，但不等于整个社会的单一态度。
- 文本分析有两种用途：一是探索语料库、发现原先没想到的维度；二是在清洗、抽样和验证后，形成可比较的描述或推断。研究问题决定你应停在哪一步。

重要转折

数据不会“自己说话”。你选择哪些文本、如何清洗、使用哪个工具、怎样给主题命名，都是研究者介入；透明记录这些介入，才能把工具输出转化为历史论证。

七、Digital Scholar Lab：把分析做成可复盘的循环

Lab 将 Gale 订阅内容与常见的开源分析工具放在同一个工作区。课堂把界面工作流概括为 Build → Clean → Analyze，但强调它不是单向流水线，而是可以随时返回前一步的迭代循环。

环节	课堂操作	产出/判断
Build（构建）	从已有馆藏检索或上传自己的文本，组成 content set（内容集；课堂说明上限为 10,000 份文档）。	明确样本边界、来源和纳入规则。
Clean（清洗）	删除数字/特殊字符/标点；find and replace 纠正系统性 OCR 错误；加入 stopwords；命名并保存 cleaning configuration。	减少噪音，同时保留可追溯的处理决定。
Analyze（分析）	添加 n-grams 与 topic modeling，运行工具，查看词云和主题可视化。	得到探索性模式，而不是未经核查的结论。
Evaluate（评估）	识别噪音，查看原文与主题内文档，挑出值得细读的词/短语。	决定下一轮只改变哪些变量。
Interpret（解释）	回到研究问题，比较结果与预期，说明限制、替代解释和下一步。	形成有证据边界的历史推论。

课堂动手练习：义和团运动数据集

- 在 Learning Center → Analyze datasets 中选择预建的 data set 6：义和团运动相关材料，时间范围 1898–1907，共 111 份文档。
- 进入 Analyze，添加 n-grams 和 topic modeling，分别运行并查看可视化。
- 先记录三类噪音：OCR 错误、无信息量的格式/标点、与研究问题无关的高频词。
- 进入 Clean，创建一个可识别名称的 cleaning configuration；设置数字/标点处理、find and replace 和 stopwords，然后保存。
- 返回 Analyze，应用该配置并重新运行；比较清洗前后哪些模式消失、哪些模式变得清晰。
- 从 n-gram 可视化中标出三个值得细读的词或短语；再检查主题模型中的文档，并为主题作暂定分类。

每次只改一个关键变量

若一次改了停用词、标点、样本和模型参数，就无法知道结果为何变化。小步迭代、保存配置、命名输出，才能把“试试看”变成可解释的方法。

八、课后回顾工作表：把课堂方法迁移到自己的项目

以下问题可直接复制到你的研究日志。不要只记录“结果是什么”，也记录你为什么这样设计、什么没有被看见，以及下次会改变什么。

阶段	回顾/记录提示
研究问题	我究竟想解释什么变化、关系、语义或历史经验？这个问题能否被一个小型实验检验？
语料库	文本从哪里来？谁选择和描述了它？时间、体裁、语言、缺失和版权是什么？
关键词	历史时期的人会怎样称呼它？有哪些旧称、拼写变体、转写、歧义词和反例？
质量控制	哪些页面/字段可能 OCR 失败？我检查了多少原图？搜索零结果是否可能是技术问题？
清洗	我删掉了什么？为什么？有没有把本来有历史意义的变体误当噪音？
工具	n-gram、主题模型或其他工具分别提供哪一种证据？为什么适合这个问题？
验证	我是否抽取了代表性、异常性和反例文本做细读？不同来源是否真的可比？
解释	我的推论超出了数据能支持的范围吗？还有什么替代解释？
伦理与回馈	谁可能受到影响？访问限制、匿名化、延迟开放和社区回馈如何安排？
下一轮	如果重做一次，我只会改变哪一个变量？我需要补读、补数据还是换工具？

一页研究日志（可填写）

日期/运行编号	
本轮只改变的变量	
观察到的模式与三个待细读位置	
噪音、缺失与不确定性	
下一步与理由	

九、术语速查与下周衔接

术语	本课语境中的简明定义
语料库 corpus	为特定问题收集、组织并可计算分析的一组文本；不是“全部过去”。
元数据 metadata	关于数据的数据，如标题、作者、日期、出版物、来源和馆藏关系。
OCR	把页面图像转换为机器可读文字的光学字符识别过程。
n-gram	连续 n 个词/字符的频率或搭配统计，用于发现重复模式。
主题建模	从词语共现中生成主题簇的探索性方法；主题命名与历史解释需要人参与。
停用词 stopwords	在特定分析中被忽略的高频功能词或无信息量词。
清洗配置	一组可保存、可重复应用的删除、替换、标准化与停用词规则。
可复现性	他人能够依据数据、代码、参数和文档重做你的过程并理解差异。
迭代方法	计划—运行—检查—修改—再运行的循环，而不是一次性得到答案。
策展/编辑选择	决定纳入什么、如何分类、如何呈现和如何关联的知识生产行为。

下周预告：空间数据与历史地图

课程将转向旧地图：如何从地图生成或描绘数据，如何探索地图中的具体信息，以及历史学者如何介入空间数据的制作、调解和解释。可把本课的同一组问题带过去：谁制作了数据？什么被省略？平台如何引导问题？

最后的回顾句

当你看到一个漂亮的词云或主题图时，先不要问“它证明了什么”，而要问：“这个结果是由什么问题、什么语料库、什么编辑选择、什么 OCR、什么清洗和什么参数共同制造的？我还需要回到哪些原文，才能把它说成历史？”

资料说明

本笔记依据 2026 年 9 月 1 日课堂录音及配套转写 PDF 整理。转写中存在自动识别造成的专名、术语和句子错误；本笔记按上下文统一了 Gale、Digital Scholar Lab、OCR、Voyant Tools、n-gram、topic modeling、义和团运动等术语，但不替代原始音频、页面图像或课程指定阅读。