HY5419 · Seminar 7

数据分析、生成式 AI 与量化历史

资料日期：2026-09-30 | 课堂学习笔记 | 原录音约 1 小时 58 分钟

这堂课最重要的一句话

> 数据、工具和模型都不会自动生成历史论证。历史学家的工作，是判断资料能否代表所研究的现实、比较是否成立，并对解释和核验负责。

三个学习目标

1. 说明 AI 何时只是辅助工具，何时已经成为研究方法的组成部分。
2. 理解模型的基本工作方式，知道哪些结果必须回到原始材料核验。
3. 将数据集视为可以比较的“案例 × 属性”矩阵，同时识别分类、语境与聚合造成的问题。

六条核心结论

- 从研究问题出发，也允许材料反过来帮助你修订问题；两者需要不断往返。
- 尽早跑通一个小规模完整流程，才能发现清理、结构与分析之间的断点。
- AI 输出流畅、语气自信，并不等于资料真实、引文准确或论证成立。
- AI 辅助远读之后，仍须亲自精读关键材料；纠错不能抹掉历史语言差异。
- 量化的前提是定义清楚分析单位、变量、分类规则和可接受的不确定性。
- 工具选择还涉及可复核性、开放性、费用与资源消耗；不必把每个任务都交给生成式 AI。

使用方式

快速复习：先读本页，再做第 14 页自测。系统复习：按第 3-12 页主题阅读，结合第 2 页时间索引回到录音。项目推进：填写第 16 页，把课堂方法转化为自己的研究决定。

整理范围：完整阅读所提供的 147 页中英转写，并对若干疑难录音片段做本地自动转写交叉核对，未对整段录音进行逐句人工听校。正文以课堂内容为主；“补充辨析”“复习示例”“实践模板”是整理者添加的学习辅助。来源和校订说明见第 17 页。

课程地图与回听索引

时间为录音起点后的时间；“原 PDF”指你提供的 147 页转写文件

录音位置	内容与复习重点	原 PDF	本笔记
00:00-02:32	上次项目展示反馈；本节课安排	1-4	1
02:33-10:24	数据如何成为论证；研究范围与迭代	4-14	3
10:25-12:31	AI 的工具／方法之分；历史学家的责任	14-16	6
12:32-35:58	LLM、token、语境、训练材料与偏差	16-43	4-5
35:59-44:37	图像分类、神经网络、权重与人工反馈	44-54	10
44:38-54:28	算力、开放性、最小计算、核验责任	54-67	6、8
54:29-01:00:38	工具与方法；监督／无监督；agentic AI	67-76	5-6
01:00:39-01:18:27	语料机器人体验、提示词、远读与精读	76-97	7、9
01:18:28-01:23:41	三层批判；AI 使用的社会性与真实性	97-104	8
01:23:42-01:33:08	手稿识别、自动纠错与模型过度自信	104-116	9
01:33:09-01:36:54	图像分类与 MapReader；迁移已有模型	116-121	10
01:36:55-01:46:28	量化历史、数据矩阵与分类口径	121-132	11-12
01:46:29-01:54:34	生态谬误、GIS、经济史与比较的边界	132-142	12-13
01:54:35-01:58:08	全课总结；下次可视化与网络分析	142-147	16

学习辅助页

第 13 页：中英术语速查与跨课联系。第 14 页：闭卷自测。第 15 页：参考答案与论述框架。第 16 页：个人项目记录。第 17 页：材料来源、转写校订与补充参考。

> 回听建议：先找不理解的概念，再回听前后 1-2 分钟。零碎转写常把一个完整句子拆开，也会把英文专名误译成普通词，不能只依赖单行中文译文。

01 从数据集走向历史论证

课堂依据：02:33-10:24 | 原 PDF 第 4-14 页

研究问题与数据之间有两条路

问题驱动：先明确想解释的历史现象，再判断数据是否包含相关字段、是否需要新增信息或重新整理。材料驱动：先探索已有数据的结构与异常，从中发现值得追问的问题。两条路都与传统档案研究相通，区别在于数据往往需要清理和重组后才能使用。

课堂案例：房价、地铁与学校

教师以新加坡房价和 MRT 站的距离为例：已有字段可能使你首先注意到交通与价格的关系；若还有学校距离、购房者或工作地点等信息，又会产生新的比较方向。能提出哪些问题，取决于数据实际记录了什么。

> 补充辨析：观察到“距离与房价有关”仍不足以证明因果。应先说明比较对象和可能同时变化的因素；本节课并未讲授完整的因果识别方法。

代理指标需要解释，而不是直接代换

课堂还提出：如果想研究性别，而原数据只有行业或商品信息，是否能找到合适的 proxy（代理指标）？关键不只是找到一个可计算字段，而是解释该字段与研究概念之间的关系，以及它会漏掉什么。

项目太大时，如何收缩范围

不要只增加资料和变量。先检查哪些问题最受现有数据支持，再缩小时间、空间、对象或比较维度。材料的限制可以帮助确定一个能够完成、能够验证的研究问题。

> 研究问题 → 初步数据 → 清理与结构化 → 小规模分析 → 检查解释 → 回到问题与数据

尽早完成一次完整流程

教师反复提醒：不要把全部时间花在寻找数据集上。先做一个初步版本，把数据送到分析和输出环节，看看哪里会失败。数字项目可能“走到接近完成，又退回修改”，并不是一直线累积成果。

我的项目检查点（整理者归纳）

- 我到底要解释什么，而不只是展示什么？
- 哪个字段能回答问题？哪个关键概念只能间接观察？
- 我最小可行的比较范围是什么？
- 我是否已经得到一份初步输出，并知道下一次修改的原因？

02 LLM：概率、语境与历史偏差

课堂依据：12:32-35:58、51:25-54:28 | 原 PDF 第 16-43、63-67 页

用“高级自动补全”理解课堂比喻

教师把 LLM（large language model，大语言模型）比作高级自动补全：根据已有上下文，预测接下来可能出现的 token，再继续生成。课堂重点是提醒我们：语言形式上的合理，不等于历史事实已经得到查证。

概念	如何理解	对历史研究的提醒
Token（词元）	模型处理文本的单位；可为词、词的一部分或标点	不能简单把 token 数当成单词数
Context（上下文）	当前任务的指令、材料和相关对话	提供年代、地区与文本用途，减少歧义
Weights（权重）	训练中形成的模型参数	输出受训练过程影响；不等于人工逐条写入的事实
Corpus（语料库）	训练或当前研究使用的一组文本材料	必须问来源、覆盖范围与缺失人群

课堂案例：weather 的不同语境

“新加坡的天气”会引向晴、雨、温度等表达；“内心的风暴”则可能涉及情绪隐喻。提供更多相关语境，有助于模型判断所讨论的是哪类含义。复习时应记住：补充语境是为了提高相关性与明确性，不是单纯增加长度。

模型为何可能带入时代、语言和文化偏差

训练材料来自特定语言、社会群体和时期；它们不是整个人类社会的平均样本。课堂用 dragon／monster 的文化联想说明，同一词语在不同语境下可能带有不同含义。历史研究尤其需要防止把现代、主流或英语语境中的常见表达投射到过去。

> 补充辨析 [A]：基础文本生成是利用已训练的模型逐步预测 token，并不是每次都回到训练语料逐条查找原句。外部检索、附件和数据库访问属于需要另行辨认的系统能力。能生成像引文的句子，也不等于已经找到出处。

应如何理解“模型是否理解”

课堂采用强烈的警示性说法，强调不要把拟人化对话当成人类式理解的证明。复习时把可操作的结论记牢：无论答案多流畅，都要检查出处、语境与论证步骤；不必把课堂比喻扩展为对所有模型能力的绝对判断。

03 分清算法、生成、训练与代理

课堂依据：31:09-33:37、55:12-01:00:38、01:33:09-01:34:25

三组容易混淆的区分

区分	第一种	第二种
专用任务与生成任务	例如计词频、识别图像类别；输出围绕明确任务	生成式 AI 产生文本、图像等内容；LLM 是其中与语言相关的一类
监督与无监督	用带标签或目标答案的样本学习，例如“猫／狗”	从未预先标注类别的数据中寻找结构，例如课堂提到的主题模型
对话与代理工作流	用户提问、模型回应，主要在对话中交互	给系统目标、角色和工具权限，让它执行多步任务；可由多个代理协作

神经网络并不等于生成式 AI。图像分类器也可以使用神经网络，但“这张图是否包含铁路”与“生成一段铁路史解释”是不同任务。使用同一类技术基础，不意味着输出的研究用途相同。

监督学习：标签本身就包含研究判断

课堂以猫的侧脸只有一只可见耳朵为例：如果过度依赖“两只三角形耳朵”，就可能误判。人工标注和反馈可以帮助训练调整；研究者需要考虑训练样本是否覆盖了实际情况。

无监督学习：自动分组仍要由人解释

主题模型给出的词组或主题，不会自动成为历史上真实存在、边界稳定的观念类别。研究者仍需命名、检查原文，并判断分组对问题是否有意义。

Agentic AI：能力来自工具，也增加操作后果

课堂将代理式 AI 比作承担具体工作的实习助手，并以误删数据库、邮件或备份的情形提示风险。研究工作中，应明确它能够读取、修改和执行什么，以及由谁检查结果。

> 实践提示（整理者补充）：涉及文件修改时，先在副本或小样本上试验，记录改动，再决定是否批量应用。角色设定和多代理协作本身不能证明结果正确。

> 补充辨析 [B]：提示词、对话中的纠正与参数训练不是一回事。增加指令可改变当前输出，但通常不会即时改写模型权重；是否进入后续训练，取决于实际系统和训练流程。

04 AI 是工具，还是研究方法?

课堂依据：10:25-12:31、44:38-55:11、01:13:23-01:18:27、01:30:34-01:32:50

核心判断：结论有多依赖模型的判断

使用情形	在研究中的作用	需要核验什么
帮我找到相关信件、提取候选段落	辅助探索的工具	出处是否真实，是否遗漏材料，节录是否脱离上下文
自动决定每封信的主题、立场或情绪，再统计趋势	研究方法的重要部分	分类规则、人工核验、错误分布，以及错误是否改变结论
辅助生成代码或操作步骤	工作流程中的工具	实际执行的代码、输入数据、输出是否正确
直接依赖模型摘要来代表整组史料	模型判断承担较重的论证责任	摘要覆盖范围、删略、偏差与可复核程度

同一技术可以处于不同位置。关键不是给某个产品永久贴标签，而是判断你的论证是否依赖它的选择、分类和概括。模型参与得越深，就越需要把验证过程写清楚。

为什么教师更倾向于把 LLM 用作探索工具

候选线索较容易逐项返回原文核查；如果把大批量模型判断直接当作研究结果，复核和再现会更困难。不同模型、版本、设置或提示词，也可能产生不同输出。课堂并非禁止使用，而是要求说明使用理由和承担的风险。

Minimal computing：用足够简单的方式完成任务

如果词频、共现词或明确的统计计算已经能回答问题，就先考虑相应的专用工具。课堂强调的衡量维度包括：费用与使用门槛、代码和处理过程能否检查、结果能否复核，以及电力、水和基础设施的资源成本。

最低限度的过程记录（整理者归纳）

记录输入材料及其版本、工具或模型名称与版本、使用日期、完整指令、可见设置、输出、人工改动和核验方式。记录不能保证完全重现，但能让读者理解结果如何形成。

> 补充辨析：让 AI 写出数字，与调用并检查统计程序的计算结果，是两种不同的证据。课堂提到统计计算可由计算机完成；这不意味着模型直接输出的数字天然可靠，或变量选择不需要历史判断。

05 课堂实践：用语料机器人辅助阅读

课堂依据：01:00:39-01:18:27 | 原 PDF 第 76-97 页

演示了什么

教师让同学探索两个定制机器人，其中一个使用三卷 Charles Dickens（查尔斯 · 狄更斯）的书信，另一个使用小说语料。教师随后展示：用户看到的对话窗口之前，已经存在材料与一套较长的任务指令。

演示中还出现把 Dickens 写成 Darwin（达尔文）的混淆，教师指出这是自己写提示词时带入的错误。它提醒我们：输入端的人为错误也会影响模型，不能把所有失误都归因于模型。

提示词背后的研究设计

指令要素	教师示范的意图
角色	作为所给作品或书信的读者，围绕资料回答
材料边界	依据提供的文件；避免任意扩展到语料之外
引文要求	给出较完整段落，保留关键词周围的语境
覆盖范围	从语料不同位置寻找多处相关材料
不确定性	信息不足时承认不足，不虚构不存在的证据
回答组织	将引文、解释与总结组织成可检查的形式

历史学家负责什么

让机器人帮助远读（distant reading），快速定位可能相关的材料；再由研究者精读（close reading），检查措辞、作者意图、时间与体裁。同一词在一封信里的用途，不能只靠词频或一句摘要解释。

> 实践模板（根据课堂思路整理，并非教师原文）：仅依据所附材料查找与“［研究主题］”有关的段落。逐项注明文件名、页码或可定位位置，保留理解所需的上下文。区分原文与解释；资料不足时明确说明；不要自动改写原有拼写或补足缺失内容。

使用之后还要检查

引文是否真的存在？位置是否对应？长引文是否只是更长而不更相关？是否只返回支持我预设判断的材料？对于“没有找到”，应检查检索范围，不能立刻推成“历史上不存在”。

补充辨析 [B]：附加材料和设置提示词，不等于已经对模型进行参数微调。课堂未展示完整技术后台，因此不把该演示擅自写成某一种确定的检索系统或训练流程。

06 三层批判与人文学科的责任

课堂依据：18:12-19:39、51:25-54:28、01:18:45-01:23:41

把传统史料批判延伸到数据与工具

层次	要问的问题	可能出现的问题
史料批判 Source criticism	谁留下材料？为谁而写？谁没有留下记录？材料能代表什么？	只有精英或识字群体的文本，却被当作全社会声音
数据批判 Data criticism	如何扫描、转写、分段、清理、编码和建表？	OCR 漏字、历史拼写被统一、空值被错误处理
工具／模型批判 Tool / model criticism	工具具体做了什么？为何给出这个结果？能否检查或复核？	分类依据不明，模型摘要遗漏反例，版本变化改变输出

三层问题彼此相连。工具再准确，也不能自动补回从未保存的史料；史料本身可信，也不代表数字化后的字段没有错误。

课堂提醒：流畅与迎合可能遮蔽问题

模型可以表现得友善、自信和乐于认同。教师谈到 sycophancy（迎合）时提醒：被肯定的感觉不等于论证经受了检验。要求模型指出反例可以帮助探索，但仍需用真实材料检查它所提出的赞同或反对理由。

AI 的使用也是一个社会过程

组织文化、周围人的态度、使用经验和制度安排都会影响技术是否被接受。因此，“可不可以用”不只是性能问题，还涉及人们期望由谁判断、由谁负责。

教学关系与真实性

课堂用教师批改作业、学生写作的例子说明：双方在意的不只是成品质量，也希望理解对方真实的思考和投入。作业是教师了解学生思考过程的一个窗口，反馈也代表教师的关注与判断。

> 可用于讨论的归纳：历史学家的责任包括选择材料、定义问题、提供语境、核验输出和解释结果。把某一步交给工具后，这些责任并没有消失。

复习时可继续追问

我的项目最薄弱的是哪一层？如果别人只看到我的最终图表或摘要，能否判断原材料、数据处理和工具选择分别起了什么作用？

07 OCR／HTR：纠错可能改变史料

课堂依据：01:15:50-01:17:39、01:23:42-01:33:08、01:50:18-01:51:10

两类识别任务

OCR（optical character recognition）指从图像中识别文字，课堂与手写文字识别 HTR（handwritten text recognition）并列讨论。教师以达尔文书信及专门的手稿识别工具为例：不同年代和写作者的字形不同，识别结果需要检查。

如果有同一人的大量信件，人工校对部分材料、形成训练样本，可能值得投入。工作量不只是让机器运行，还包括确定正确文本、理解书写习惯和处理难辨字词。

“更干净”的数据不总是更好的数据

若错误来自扫描或识别，修正有益；若看似错误的形式实际上是历史拼写、方言、非标准表达或研究对象本身，自动标准化可能消灭证据。研究语言差异时尤其要谨慎。

课堂案例：paddy 被误当作错误

同学报告，模型在描述父母职业的句子中，把与 paddy（水稻）有关的表达当成可疑 OCR 错误，并提出另一个“更合理”的解释。教师追问：在对应地区和时期，父母从事稻作是否本来就合理?

这个例子说明：局部语言搭配的“常见”，不能代替地区和社会史知识。原 PDF 对整句及替换词识别不稳，本笔记保留概念层面的案例，不把残缺转写当作精确引文。

更可检查的纠错流程（整理者归纳）

> 原图／原转写 → 标记可疑处 → 提出候选与依据 → 人工对照 → 保存原文和修改记录

记录项目	应留下什么
原始位置	文件、页码、行或图像区域
修改内容	原形式 → 候选形式；不确定时保留多个可能
外部依据	字形、上下文、同一作者用法或历史背景
最终决定	接受／拒绝／待核；由谁在何时确认

> 课堂警示：模型自报“90%”或“95%”的信心，不等于经过验证的正确率。它给出的修改解释也是待检查的输出，不能单凭解释流畅就接受。

08 图像识别与 MapReader

课堂依据：35:59-44:28、01:33:09-01:36:54 | 原 PDF 第 44-54、116-121 页

从像素、特征到分类

课堂用猫／狗的识别来解释模型：栅格图像由像素构成，可形成线条、形状及更复杂的特征；模型综合信息，判断类别。教师用三角形耳朵、圆形和鼻子等直观例子说明，依赖单一特征容易失败。

> 补充辨析 [C]：这是教学示意。现代神经网络能够从训练数据学习复杂模式，不应把所有图像分类器都理解为人工写死的“三角形数量规则”。“权重”也不等同于每项特征的直观百分比。

人工标注为何不可省略

哪些图像算作目标？遮挡、残缺或模糊情况怎样处理？一张图中出现多个对象怎么办？这些决定影响训练材料，也影响我们最终说“机器识别出多少”的含义。

课堂案例：历史地图中的铁路设施

教师介绍 MapReader：利用已有模型并针对历史地图的视觉特征作调整，识别铁路及相关设施。核心启发是，不一定从零建立一个模型；已有方法能够经过适应，用于新的历史材料。

名称核对 [D]：MapReader 官方文档将其描述为用于大规模图像探索和分析的工具，其中分类流程可预测地图切片的标签。此处仅用于核对项目名称与基本任务。

迁移学习与“最小计算”的联系

复用既有技术可以减少从头开发的成本，但“已经在别处有效”不保证在你的地图上仍有效。符号、比例尺、年代与印刷方式的变化，都应在项目设计时纳入检查。

历史学家的主要贡献在哪里

课堂强调，重要的智力工作常在问题设计、范围控制、标注数据集及历史解释。课程项目不必以独创底层算法为目标，应先说明任务是否值得做、材料是否适合，以及输出能支持什么论证。

我的图像项目检查点（整理者补充）

- 我识别的是图面上的符号，还是现实中的设施？两者有什么区别？
- 我是否定义了正例、反例和不能确定的例子？
- 我是否在未参与训练的材料上检查过结果？
- 地图上“没有识别到”可能来自缺图、漏画或漏检吗？

09 量化历史：案例与属性的矩阵

课堂依据：01:36:55-01:42:40、01:51:11-01:54:34、01:55:41-01:56:58

从单一事件到可比较的多个案例

传统叙述可以围绕某一次选举解释前因后果；量化研究可能把它变成一行数据，与其他选举比较。由此得到的力量是发现跨案例的结构与变化，代价是必须判断：不同年代的事件究竟在哪些方面可比？

量化并不陌生

此前文本分析中的词频和共现计数已经包含量化。课堂回顾了 20 世纪 60 年代量化历史兴起的乐观期待：聚合资料可能帮助研究普通人的生活，扩展直接叙述性史料的范围。计量史学（cliometrics）是课堂提到的相关术语。

数据矩阵的基本结构

一行是一项案例或分析单位（unit of analysis），一列是该案例的属性或变量（attribute / variable），标识符把相关信息连起来。它与 GIS 属性表的结构相通。

案例 ID	年份	地点	观察对象	比较属性
A	某年	某地	一次事件／一个单位	价格、人口、类别等
B	另一年	另一地	同层级的事件／单位	使用相同定义记录

上表为结构示意，不是课堂提供的真实数据。

“能放在同一张表”不等于“可以直接比较”

课堂用不同年代的美国总统选举说明：事件名称相同，但制度背景、人物、争论和社会条件可能不同。研究者要解释，所选择的共同属性为何仍有意义，以及哪些差异不能被表格抹平。

与经济史的关系

量化历史与经济史高度重叠，也涉及人口史、社会史和空间研究。课堂讨论进一步指出，即使是价格、贸易量或 GDP，也包含定义和跨时代适用性的问题。总体经济指标未必充分代表普通人的实际生活；新材料可能改变既有理解。

> 本节主线：量化可以扩展史料的解释能力，却不能取消史料批判。关键不是“数字是否客观”，而是数字如何产生、代表什么、可与什么比较。

10 分类、测量、不确定性与生态谬误

课堂依据：01:41:45-01:50:18 | 原 PDF 第 127-137 页

数字的意义取决于记录规则

边界长度使用米还是公里？是否四舍五入？“母语”“第一语言”“日常使用语言”如何定义？这些不是表格之外的小事，而是决定变量含义的基础。

课堂案例：新加坡语言分类

教师用语言分类说明，行政或教育制度采用的类别，不一定等于人们实际使用语言的方式。不能仅从族群或母语类别，直接推断英语能力或日常语言使用；不同地区的分类口径不同，也会妨碍跨国比较。

范围说明：这里只保留“分类影响解释”的方法论结论。转写中的人口百分比、语言考试与国家分类说法，不作为核实后的统计事实或现行政策记录。

计算正确，仍可能解释错误

如果字段并不代表你想研究的现象，程序可以完全正确地计算出一个不适合回答研究问题的结果。研究者必须先验证“这个数代表什么”，再解释它们之间的关系。

接受多少不确定性，要看研究问题

课堂指出，某种精度对一个问题足够，对另一个问题未必足够。例如，边界长度四舍五入是否重要，要看它会不会改变比较和结论。应明确记录误差来源与选择理由。

> 实践提示（整理者补充）：若合理改变分类、精度或可疑记录的处理方式，结论就翻转，应报告这种敏感性，或缩小结论范围。

Ecological fallacy：生态谬误

把群体层面的统计特征，直接推成某个个体的属性或行为，就是本节提示的生态谬误。聚合数据回答的是特定层级的问题，不能自动替代个体证据。

> 复习示例（非课堂原始数据）：某地区 70% 的选票投给候选人 A，不能据此断言住在该地的某个人投给了 A。知道地区总体比例，与知道这个人的行为，是不同的信息。

与 GIS 地面控制点的联系

教师回到之前的 GIS 练习：把旧地图上的一点与现实地点对应，也要求你足够理解地方和历史语境。无论坐标还是统计数字，都需要有人判断它与世界的对应是否成立。

11 中英术语与跨课联系

术语依课堂语境规范化；部分英文在原转写中存在误识别

英文	中文与复习要点
Research question / Scope	研究问题／范围；由问题、材料与时间共同约束
Proxy	代理指标；可观察字段与研究概念之间需要论证
LLM / Generative AI	大语言模型／生成式 AI；二者不能与所有算法混同
Token / Tokenizer	词元／分词器；词元未必是完整单词
Corpus / Context	语料库／上下文；材料集合与具体解释语境应分清
Weights / Training	权重／训练；模型参数及其学习过程
Supervised / Unsupervised	监督／无监督；有标签学习与探索数据结构
Ground truth	参考真值或人工核验基准；其形成也需要说明
Agentic AI	代理式 AI；围绕目标调用工具、执行多步任务
Hallucination / Sycophancy	幻觉／迎合；貌似合理但不可靠的输出与附和倾向
Distant / Close reading	远读／精读；发现整体模式与检查具体文本
OCR / HTR	光学字符识别／手写文字识别
Minimal computing	最小计算；选择足以完成任务且负担适当的方法
Quantitative history / Cliometrics	量化历史／计量史学；相关而不完全等同的概念
Unit of analysis / Attribute	分析单位／属性；一行代表什么、一列记录什么
Ecological fallacy	生态谬误；从聚合特征直接推断个体
GCP: Ground control point	地面控制点；建立地图与现实位置的对应

把本节放回整门课

文本分析：计数和主题结构提供线索，仍要回到语境。GIS：空间位置、属性与来源连接起来，增加比较能力。生成式 AI：在既有史料批判之上，需要进一步检查模型的取舍和输出。量化历史：将多个案例组织成共同结构，但必须解释这种比较为何成立。

> 共通问题：材料经过了哪些转换？每一次转换保留了什么、损失了什么？这些变化会不会改变我的历史解释？

12 闭卷自测

学习辅助：由本次课程内容整理，非教师指定题目；参考答案见第 15 页

概念与区分

1. 为什么“已经收集了大量数据”不等于“已经形成历史论证”？请给出下一步行动。

2. Token、训练语料与当前上下文有什么不同？为什么流畅回答不能证明出处真实？

3. 同样是给信件分类，什么情况下 AI 只是工具，什么情况下已成为研究方法？

4. 给模型补充提示词，与训练或微调模型有什么区别？

应用与判断

5. 用三层批判分析一组“扫描、OCR 后交由模型摘要”的殖民时期报纸。

6. 为什么研究历史拼写时，AI 的“自动纠错”可能使数据质量变差？

7. 如何使用课堂的语料机器人，而不把远读结果直接当成最终证据？

8. 比较两个时代的选举或经济指标之前，你至少应检查哪些条件？

9. “某地区大多数人从事农业，所以某个居民也是农民。”问题在哪里？

10. 你的项目最值得先跑通的“小规模完整流程”是什么？如何判断它失败或成功？

13 自测答案与论述框架

学习辅助：参考答案强调推理要点，不是唯一表述

自测参考答案

1. 数据必须通过问题、变量与解释连接起来。先选一个具体问题，检查字段和材料覆盖，再做能检验想法的小规模分析，必要时修改范围。
2. Token 是文本处理单位；训练语料是模型学习时接触的材料；当前上下文是本次任务实际提供的信息。语言生成并不自动提供可核查出处，仍须查原文。
3. 若模型只提供候选材料，研究者逐项验证，主要是辅助工具；若模型的标签成为统计结果或历史结论的基础，它就是方法中的关键环节。
4. 提示词改变当前输入条件；训练或微调涉及参数学习。不能把一次对话中的纠正自动当作模型已经完成永久学习。
5. 史料层检查报纸的生产者、读者与缺失声音；数据层检查扫描、OCR、分段和清理；工具层检查摘要的遗漏、偏差和可复核性。
6. 历史异体、地方表达和非标准拼写可能正是研究对象。应保存原图与原转写，区分识别错误和历史差异，记录每一项修改。
7. 限定材料范围、要求可定位引文和必要上下文，查阅语料不同位置，亲自精读关键证据；摘要只用于定位和组织线索。
8. 检查分析单位是否一致、变量定义和单位是否相同、制度及语境是否变化、样本是否可比、缺失与不确定性是否影响结论。
9. 这是生态谬误：把群体比例变成个体事实。只能说明群体层面的分布，个体职业仍需个体证据。
10. 答案因项目而异，但应覆盖“取样 → 清理 → 结构化 → 分析 → 输出 → 回查”。成功标准须与研究问题有关，不能只是软件正常运行。

讨论题：AI 如何改变历史学家的工作?

可先提出判断：AI 能改变处理材料的速度与方式，却不会取消历史学家的责任。接着用语料机器人说明探索效率，用 OCR 纠错说明语境与偏差，再用量化矩阵说明比较的前提。最后解释，在什么边界和核验条件下，你愿意使用这些输出。

> 论述顺序建议：研究问题 → 具体材料 → 工具承担的任务 → 新增的解释风险 → 如何核验 → 结论能说到哪一步。用一个案例把各环节连接起来，比只罗列 AI 的优缺点更有说服力。

14 我的项目与学习记录

可直接打印填写，也可使用 PDF 批注工具记录

把本节内容转化为一次研究决定

我的项目主题与本次记录日期：

我的研究问题（一句话）：

我的分析单位是什么？最关键的 2-3 个字段／代理指标是什么？

这组材料能代表什么？它遗漏了哪些人、时期或现象？

我准备让工具／AI 完成哪一步？这一步会不会直接决定结论？

我要如何核验？哪些记录将保留原始版本与修改痕迹？

本周可跑通的最小流程、完成标准和下一步：

学习反思

本节改变了我的哪个看法？我仍想问教师什么？

> 下次课预告（01:57:04 起）：可视化、信息的呈现与理解，以及关系数据和网络分析。可提前想一想：我的数据要向读者展示什么关系？如果研究“谁与谁联系”，一条关系记录需要哪些信息？

15 来源与校订说明

本页区分课堂材料、局部录音核对和整理者补充

主体材料

主要依据你提供的《数字历史课程：数据分析、生成式 AI 与量化历史导论》转写 PDF 与同名 WAV（文件标记：202609302137，有道留学听课宝）。PDF 共 147 页；WAV 时长约 01:58:18。所有课堂时间索引均对应这份录音，页码对应原转写的实际 PDF 页序。

正文按主题重组并删去重复、停顿与无关片段；中文是概括整理，不是逐字译文。未将原文件夹其他阅读材料或个人反思当作本次课堂发言。

疑难片段的本地核对

对 01:05:50-01:07:35、01:28:28-01:29:38、01:34:15-01:35:55、01:37:40-01:39:10 做了本地自动转写交叉核对，用于帮助辨别书信作者、纠错案例、地图项目与量化历史术语。自动识别仍可能出错，不等于逐句人工听校。

原转写常见问题	本笔记的处理
LM、LMS、LLS 等混写	按明确语境统一为 LLM
tocanaser、weeks、HDR 等	分别按语境规范为 tokenizer、weights、HTR
Dickens 与 Darwin 混淆	区分狄更斯书信机器人与后面的达尔文手稿；保留教师输入错误这一课堂提醒
Matt Reader、geometrics 等	结合上下文与局部录音，规范为 MapReader、cliometrics
模型型号、token 上限、专名和数字失真	不补造无法确认的细节；保留与本课有关的方法论结论

补充参考：用于技术辨析，不是课程指定阅读

[A] Hugging Face：Text generation。支持第 4 页关于逐步生成 token 与生成配置的辨析。

[B] Google ML Crash Course：Fine-tuning, distillation, and prompt engineering。支持第 5、7 页区分提示词与参数训练。

[C] Google ML Crash Course：Neural networks。支持第 10 页关于学习复杂模式、训练与教学比喻的辨析。

[D] MapReader 官方文档。用于第 10 页核对项目名称和地图切片分类任务。

整理者新增的练习、流程建议和判断示例已在相应位置标明。课堂关于语言政策、产品性能、资源消耗的零散说法未扩展为现行政策、产品推荐或量化事实。