HY5419 数字史：项目讨论、数据可视化、众包研究与数字媒体保存

课程学习笔记｜基于完整转写稿整理｜初学者版

> **材料范围**：双语转写 PDF，共 156 页；原始 WAV 录音约 2 小时 22 分钟（转写最后时间戳约 02:21:19）。文件名称包含“数字历史项目讨论：可视化、数据清理、众包与媒体保存”。根据课堂谈及 Gephi、数字史、课程项目与下一周安排，课程识别为 **HY5419 Digital History**。
>
> **核验声明**：已读取完整 PDF 的英文转写并检查 WAV 文件的格式、时长及多个片段的音频信号；但本次**未完成逐段人工听辨及关键语句的录音语音核对**。故不能把本笔记称为“已核对原始录音的逐字准确版本”。以下主要依据英文转写，中文机翻仅作定位辅助；明显术语误识别依上下文作谨慎规范化，并在第六部分列出。疑难处标记【待核对】。
>
> **标记规则**：**【课堂内容】**为教师或同学在转写中确实讨论的内容；**【补充解释】**是为帮助初学者理解而加入的说明或演示，不能当作教师原话；**【建议优先掌握】**是笔记整理者依据课程内容提出的复习建议；**【老师明确提及的考核/提交要求】**仅用于教师明确说过的安排。课堂中的第三方纪录片片段会特别注明，以免误当作老师发言。

一、课程概览

本节课首先回应前一周有关网络分析、数据可视化与数据清理的问题，随后让同学们报告各自数字历史项目的实际困难，并讨论期末展示与个人反思论文的定位。在后半节课，老师讲解了**众包研究（crowdsourcing）**如何把规模庞大、机器难以处理的历史材料转化为可分析数据；最后通过一部追索迪士尼频道短促片头音乐的纪录片，讨论**数字媒体保存（digital media preservation）**、非正式档案、历史资料的选择性留存，以及法律与研究伦理。

学完后，应该能够：先明确历史问题，再选择合适的数字工具；解释“数据本身已经被整理和解释”这一核心观点；对网络中心性、脏数据与误导性图表作出基本判断；设计一个可实施、可追溯的数字史项目原型；理解如何组织可信的众包转录；并识别数字媒体保存中有关语境、所有权、公共价值和档案选择的关键问题。

本节课的讨论顺序

时间	讨论主线	本笔记对应
00:00–24:30	可视化、中心性、数据清理、可重复性、误导性展示	2.1–2.5

时间	讨论主线	本笔记对应
24:30–43:30	项目难题、Gephi 保存、展示与论文、经费和意义	2.6–2.7
43:30–1:01:30	创建数据库、家庭档案、地名变动和历史语境	2.8
1:01:30–1:13:55	敦煌项目、Gephi 是否必需、时间数据、自动抓取伦理	2.9–2.10
1:17:00–1:46:00	众包的任务设计、质量保障、社群管理和同意	2.11
1:46:00–2:21:19	数字媒体保存与纪录片、法律伦理、课程收尾	2.12

二、详细学习笔记

2.1 数据可视化首先是历史解释：数据集也不是“中立原料”

定位：01:07–02:35；04:48–05:16；43:54–45:14。

【课堂内容】同学提出如何尽可能“真实”地使用可视化，避免解释带偏研究。老师没有把问题局限为“图应该怎么画”，而是指出更靠前的一层：**数据集在被画成图之前就已经经过选择、分类与整理（curation）**。可视化是解释行为，数据建立本身同样是解释行为。不能假定数据先天纯净、客观，只有画图环节才加入研究者判断。

例如，从原始史料到结构化表格，需要决定什么算一条记录、哪些信息是同一类别、冲突记载如何编码、是否保留不确定关系。老师举了人物关系如何分类的例子：一组关系可能兼有家庭、敌对等不同含义。不同决策将影响最终网络图及其历史解释。**真正要问的是：如何使这些解释性决策透明，让别人理解、检查并尽可能复现？**

老师提出最直接的办法是公开（或至少在适当范围内提供）**数据集和配套文档**，交代数据如何组织、为何如此分类以及如何从数据转成图。这里的“透明”不是展示一张漂亮的成品图，而是展示研究路径与决策。

【补充解释】可以把数字史过程理解为：`史料 → 选取/定义变量 → 分类与清理 → 构建数据集 → 分析 → 可视化 → 历史解释`。箭头每一步都包含选择。某项决定如果改变了“谁与谁相关”或“什么事件被纳入”，它就属于需要记录的方法论决定，而非可以隐藏的机械操作。

易错点：① 图形精美不等于研究可信；② 数据“从档案抄来”并不表示没有诠释；③ 公开数据若没有字段说明、来源与清理日志，透明性仍然有限。

2.2 选择哪一种图：先想想要证明什么，不要先选软件

定位：02:42–05:16；17:05–22:12。

【课堂内容】对于同一主题，应该展示广泛趋势还是细节？老师的答案是 **it depends on what you want to show**：可视化是为了揭示数据特征、趋势或关系，要反过来从研究问题决定形式。

研究想回答的问题	课堂提及的常见形式	它突出什么	警惕
历史事件/对象分布在哪里?	地图（map）、可能的专题地图	空间位置与分布	地图定位、范围及地理单位是否一致
随时间如何变化?	时间轴（timeline）、折线图（line chart）	时间序列与转折	时间尺度和缺失年份
谁和谁联系？信息如何流通?	网络图（network visualization）	连接结构、团体和中介节点	“有连接”不等于因果或影响力已被证实
若干类别的数量有何差别?	条形图（bar chart）	数值比较	纵轴基线、刻度、单位
何种变量最能解释观察?	探索性图表，多种形式尝试	发现意外模式、缩小变量范围	不要把探索中出现的相关性直接当结论

老师特别提醒谨慎使用**饼图与环形图（pie/donut chart）**：它们可能使份额比较不直观或误导。老师并未给出“任何情况禁止使用”的机械规则；重点是检验呈现方式是否忠实反映数值。

可视化的双重用途：一是把已经明确的发现传达给别人；二是用于探索（exploratory analysis），帮助研究者从大数据集里发现值得进一步问的问题。因此不必一开始就知道成图长什么样。老师还建议参考前一周幻灯片中的可视化案例网站；**网站地址没有出现在转写中，需回查课件**。

2.3 网络分析：三个中心性指标分别在测量什么

定位：05:21–11:01；这部分存在明显语音识别错误，以英文上下文为准。

【课堂内容】老师强调，网络分析软件给出的数值，**必须放在同一网络、同一计算方式及历史语境中比较**。一个孤立的“2”本身说明不了多少；若其他节点的数值都接近 0.1，那么 2 可能很突出。更重要的是，研究者要把数值与历史角色或行动联系起来，而不能让算法自动代替解释。

指标	初学者的理解	课堂对应的历史问题	不能直接推断的事
度中心性（degree centrality）	一个节点与多少其他节点直接相连	谁最常出现在关系网里、联系最广或可见度最高?	联系多 ≠ 必然有最高权力或真实社会声望
中介中心性（betweenness centrality）	一个节点多大程度处在其他节点之间的最短路径上	谁连接不同群体，是桥梁、经纪人或“守门人”（gatekeeper）?	数值高 ≠ 此人实际控制全部信息流
特征向量中心性（eigenvector centrality）	不只看连接数，还看连接对象本身有多重要	谁虽认识的人不多，却与关键人物相连，因此可能有影响力?	与重要人物相连 ≠ 已证明具有独立影响力

老师用“社交关系中的影响力”解释特征向量中心性：某人可能只有五个联系，但这五个人各自与许多人相连；另一个人联系了上百人，可是对象大多不重要。两人可能形成“**低度中心性但高特征向量中心性**”和“高度中心性但相对较低特征向量中心性”的不同组合。老师用顾问、商业领袖和权力中介作历史类比，说明“认识对的人”有时比“认识很多人”更关键。

【补充解释】为便于理解下列是**定义式，不是老师在课堂上板书或推导过的公式**。在简单、无向、未加权网络中，节点的度可写成：

$$k(i) = \sum_{j=1}^{n} A_{ij}$$

其中，A_{ij} 表示节点 i 与 j 是否直接相连（相连记 1，否则记 0）。$k(i)$ 是连接条数，**没有物理单位**。如果是有向或加权网络，入度、出度与权重的处理会改变定义，不能机械套用。

中介中心性常定义为：

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

其中 σ_{st} 是节点 s 到 t 的最短路径总数，$\sigma_{st}(v)$ 是这些路径中经过 v 的条数。不同软件可能进行归一化，因此**跨网络比较前必须核对计算设置**。特征向量中心性则用邻接矩阵与其特征向量表达，直觉上是“重要节点的连接会使我更重要”。课堂主要解释指标的历史含义，并未正式推导这些公式。

【建议优先掌握】拿到 Gephi 结果，不要写“这个人物中心性为 0.4，所以他很重要”，而应先问：网络以什么关系定义边？这个指标测什么？其他人物的数值是多少？这与哪条史料、哪种历史机制相符或相悖？

2.4 脏数据、数据清理与可复现文档

定位：11:10–17:04。

【课堂内容】数据清理（data cleaning）的目标不是任意“修正历史”，而是使不同记录能够按一致规则进行比较或计算。老师以电影标题为例：若字段本来应只装电影名称，却混入 `title:` 之类前缀，就属于格式不一致。有些错误可用统一规则批量修正；有些混杂情况无法机械识别，必须逐条人工判断。老师建议尽量寻找起点相对干净的数据，也承认历史项目经常不得不清理。

批量清理与人工判断的差别：如整列都存在完全一致的前缀，剪除前缀是一项可检查的规则操作；但若有错别字、别名、相互矛盾的信息或字段里混入多种东西，就需要回到史料与上下文。**不能把“自动匹配成功”当成事实已得到考证。**

老师推荐一个开源、可在自己电脑上运行的数据清理工具。转写识别为“Urban Refine”，根据所述性质与用途，**很可能是 OpenRefine**；由于尚未听辨录音，保留此术语核对提醒。老师表示可以向他咨询数据清理问题。

另一位同学问：看到别人最后的图，如果没有 README、方法说明，能否逆向重建？老师指出很困难，至少需要知道数据是什么、时间和空间范围、使用的字段，才能推断绘图过程。如果完全缺少原始数据，也可能自行搜集相似数据，尝试重建一张地图，但这不是对原图制作过程的确证。

老师建议在可视化旁的脚注、说明或 README 中交代：史料和数据来源；纳入/排除条件；对数据进行了哪些转换、合并、筛选；时间和空间范围；局限和不能代表什么；关键软件与版本（例如 Gephi 版本或算法设置）。当结果依赖软件输出的数值时，版本尤其重要。这与网页资料注明访问日期的逻辑相近——让别人能够追溯所见的版本。

【补充解释：建议的数据清理记录模板】

要记录什么	可填写的内容（示例，不是课堂原数据）
原始字段	`person_name_original`、`date_original`
规则	删除固定前缀、统一日期顺序、保留原文字段
需人工判断	同名异人、年代缺失、地名跨时期变化
决策依据	原始页码、数据库网址、参考文献、处理日期
不确定性	无法确定者保留原值并标记，勿擅自填实

2.5 “图中的数字是真的”，仍可能构成误导

定位：17:05–24:27；老师展示的原始幻灯片/图表未上传。

【课堂内容】老师让同学们辨认几张有问题的图。第一类是份额图的视觉面积与数值不一致：转写出现 **56 与 44** 的比较，本来 56 大于 44，图形却给人相反印象。第二类问题是**刻度、轴线或大小比例**不合理，使不同年份或类别的差别被放大、缩小，甚至造成“经济下滑”的错觉。第三类涉及汽油价格涨幅：即使旁边印着真实数值，**向下箭头、颜色或视觉方向**也会把上涨包装成下降。老师追问：如果他没有提前提醒哪里不对，观众会逐项检查数字吗？很多人不会。

【待核对】案例中涉及马来西亚图表、汽油价格、政治人物及若干百分比，但转写存在严重错字且缺少幻灯片。不能把含混的 `20% / 75% / 15%` 或全部例图归属当作已核对事实；这里只保留老师明确想说明的**可视化可能扭曲事实的机制**。

更深的一层，是**数据分类（classification）本身可能承载价值判断和权力**。老师以新加坡林地被分作“原生林 / 次生林（primary / secondary forest）”为例：一旦把次生林理解为“被清理过、重新长出来、因此比较可以牺牲”，就容易将分类标签变成价值排序；然而“曾被砍伐”不等于森林不重要。数据表面看起来只是中性分类，实际上可能影响公众怎样理解开发与保护。

这部分与 2.1 构成首尾呼应：**不仅“如何画”影响理解，“用什么类别来数”也会影响历史解释。**

2.6 项目工作流、Gephi 保存问题与两类课程产出

定位：24:30–31:51；同时参照 42:36–43:28、58:44–59:06。

【课堂内容】同学使用 Gephi 时发现，修改设置后如果没有正确保存，可能丢失数天工作，甚至不确定最终看到的是不是自己想要的配置。老师建议保持一个**独立于软件的工作日志（working journal）**：每次调整写下日期、操作和发现，并在记录操作时同步确认已经保存；另采用版本号或日期命名保留多个版本，避免一次误操作破坏全部成果。

【补充解释：可实行的操作顺序】①复制一份原始数据；②导入并记录文件名与字段；③每次改变筛选、布局或统计参数时记下设置；④立即保存项目并用版本号识别；⑤导出图像/表格时注明产生它的项目版本；⑥记录没有成功的尝试及原因。具体“保存”按钮与菜单会因 Gephi 版本变化，需要以实际界面为准。

本节最重要的项目要求，是老师区分了**期末展示（presentation / funding pitch）**与**个人反思论文（critical reflection essay）**。

项目	期末展示（pitch）	个人反思论文（essay）
核心问题	“我们目前做出了什么？为什么值得继续支持？”	“我是怎样做到的？哪些尝试失败了，为什么？”
重点材料	当前最有说服力的发现、可运行原型、未来可扩展方向	研究选择、资料困境、方法调整、失败、反思和限制
面向谁	想象为潜在资助者、项目支持者	老师评价你的学习过程与研究判断
完成程度	不要求整个宏大设想已经全部完成；需要能证明概念可行（proof of concept）	允许详写尚未解决的问题与后来改变的方向
小组项目	可以合作展示	**老师建议写出各自不同的个人视角**

同学提出以历史建筑保护为题，希望做整片区域的 3D 模型，但目前只能集中处理一栋建筑；老师说这恰恰可以当成“**概念验证（proof of concept）**”：先证明一栋建筑的办法行得通，再在 pitch 中讲清未来若有更多时间、经费和资料，怎样推广到其他建筑。未做成的部分则适合放入反思论文。

【老师明确提及的考核/提交要求】转写显示期末展示安排在 **Week 11 和 Week 12**，老师说每组**大约 5–6 分钟**，并建议内容聚焦；可通过邮件向老师表达倾向的展示周次，老师在课上提到“本周”发送意向。由于课堂表述中也有未听清处，这些属于**当时口头安排**，具体时长、分组名单和最终截止时间仍应以课程公告为准。老师还说较早展示的同学会考虑准备时间差异，但相关句子无法可靠还原，不能推断评分优待细则。

2.7 历史研究为何值得资助：学术空白、社会关联与风险

定位：31:51–43:28。

【课堂内容】同学问，商业公司以盈利衡量价值，历史研究又如何论证项目经费？老师指出：申请通常要说明一个**知识缺口（knowledge gap）或学术空白（academic gap）**，不一定必须证明立刻产生可量化的社会效益（impact）；与此同时，不同资助机构的关注点很不一样，有的按公共政策主题征集，有的愿意支持较自由的**蓝天研究（blue-sky research）**，即短期实用性不明显、但能扩展知识边界的研究。

课堂将研究环境、资助主题及政策转向联系起来，提到智慧城市、健康、老龄化、认知福祉、数字研究中心等例子。老师谈到博物馆活动可能帮助长者回忆、叙事、反思并提升自身经验的价值感，但同时也强调评估

很复杂：认知与情绪交织，标准化测量仅是代理指标（proxy），记忆叙述并非简单的“真假测试”，样本量、志愿者参与情况和情境差异都会影响结论。**这里不是在课堂上证明博物馆项目一定具有特定医疗疗效。**

老师还指出数字项目特别容易受经费变动影响：技术平台、工程人员、已有数据环境和社群需要持续维护，一旦资金方向变化，项目可能迁移、暂停或终止。

将这一部分落实到自己的项目，可以区分三层理由：**历史问题为什么值得问；当下原型已经提供什么证据；若扩大规模，还能对哪些领域提出有意义的新问题**。老师用小规模街区、建筑、地名、迁移和历史经济结构等例子说明，研究对象很小，不代表学术问题也只能很小。

2.8 同学的研究项目：当资料结构与最初设想不一致

定位：43:54–1:01:30。

案例 A：建立家庭档案与关系型数据库（relational database）。一位同学已经在自己的设备上搭建开源数据库系统，并分别设计文献（documents）、人物（people）和物品（objects）的元数据模板（metadata templates）。少量样本测试可行，但家族材料多达数百件；若逐件扫描、OCR、录入元数据再批量导入（bulk upload），会耗费很长时间。同学还想开发公众可访问的网站，但目前数据库后台与前端衔接尚未完成。

老师的反馈有两个层次。**短期先建立能运行的最小样例**，验证数据模型和录入流程；不需要在一个学期内把全部材料数字化。之后再讨论规模化（scaling up）。同时老师认为，数据库与公共访问界面的关系、私密与开放信息的访问区分，是值得认真思考的设计问题；不必让大量重复录入挤占全部学习精力。该项目涉及跨境迁移、印度尼西亚和殖民史材料，部分记录可能只向家人开放，部分可面向公众。

【补充解释】数据库可以先选择每类资料少量、有代表性且权属清楚的样本，检验三个问题：**能否记录来源？能否正确关联同一人物与文件？能否合理控制访问权限？** 这是原型设计建议，并非教师指定的技术路线。

案例 B：历史地名会移动，地方也不是不变的容器。另一位同学研究新加坡一个与胡椒、甘蜜（gambier）种植、社群历史有关的地方，发现旧地图标注、现代水库位置与地方名称并不重合。最初以为自己在查一个稳定存在的地点，研究深入后才发现**名称指向的区域可能随时代改变**。转写中地名被反复识别成 `Tractor Con / truck to come` 等形式，无法可靠确定拼写，故不在这里擅自改为具体地名。

老师据此追问：什么定义了一个地方？是固定坐标、地理边界，还是生活在其中的社群？如果社群迁走，地方认同是否也可能随之改变？这不是一个应尽快“清洗掉”的误差，而可能**正是研究发现**。旧地图、地名变化、档案目录的命名与种族/职业分类，都会塑造历史学家能够检索、描述和解释的对象。

老师特别谈到档案把某些活动归入某族群历史，而不是种植业史或经济史的情况：**归档和编目（cataloguing）不是中性渠道**，它们可能让人们习惯于用族群与职业的对应关系理解新加坡历史。研究者可以重新提问：该地区除了经济活动，还关联环境史、社区史、国家规划与城市现代化吗？

从具体案例走向广泛意义：老师建议在展示中说明一个局部发现如何连接到更大的历史问题，如迁移、社区构成、经济结构、国家规划和空间改变。期末展示面向未来：“我们走到这一步，还能去哪里？”反思论文面向过程：“我是怎么走到这一步的？”

2.9 与敦煌有关的课堂提问：Gephi 必须用吗？数据格式怎么决定？

定位：1:01:44–1:08:30。这一段直接涉及敦煌藏经洞第 17 窟（Cave 17）及文书流散项目。

【课堂内容】有同学提出：自己的研究是在说明敦煌写本的联系及重要节点，网络并不复杂，为什么必须用 Gephi？可否使用其他工具直接画出关系？老师回答得很明确：**Gephi 是一种工具，不是数字历史研究的强制标准。** 若只需要展示一组数量较少、关系明确的节点，使用 PowerPoint 手工绘制网络也完全可以。Gephi 的优势主要出现在两种情形：①需要软件帮助**探索**大量关系，发现人眼无法直接辨认的群组、孤立节点和连接模式；②需要计算中心性等**网络分析指标**，而不只是制作关系示意图。

老师又把敦煌项目重新拆成几种相互联系的历史问题：

1. **网络问题**：藏经洞文书通过哪些人物、机构与交易过程相互连接？
2. **地理问题**：文书从敦煌流向哪些地方？可能经过哪些空间路线？
3. **权力结构问题**：哪些人或机构有能力取得、转移、收藏或解释这些文书？
4. **知识与艺术流通问题**：文书及相关知识如何经由上述关系传播？

老师提醒：**人的位置和他与机构的关系可能共同解释为何某部分收藏流向特定地点**。如果只画“甲—乙—丙”的关系线，却不记录时空背景，可能错过重要历史机制。软件只是帮助你把这些问题看清楚，研究问题才决定工具的选择。

关于数据整理，老师说**一致性（consistency）至关重要**。日期可以使用国际标准化组织（ISO）的通行格式，如年-月-日；更完整的时间写法可包含时、分、秒。关键在于后续软件能够正确读取、比较和排序历史时间。老师特别提到，Excel 对较早的历史日期可能不适用或无法识别，因此历史学家有时会把**年、月、日拆为独立字段**，避免强制套入现代电子表格日期系统。

【补充解释：针对敦煌数据的一种可行结构，非教师提供的模板】

数据表/字段	具体作用	为什么需要
`nodes.csv`：`id`、`label`、`type`	记录人物、机构、地点等节点	不要把名字相同但历史身份不同的对象误合并
`edges.csv`：`source`、`target`、`relation`	记录有方向或无方向的联系	明确“持有”“转交”“购买”“收藏”等关系不是一回事
`date_original`、`year`、`month`、`day`	同时保留原记载与标准化字段	让近代日期可排序、古代或不完整年代不被伪造为精确日期
`place_original`、`place_id`	记原地名及后续地理匹配	避免地名变动制造错误位置
`source_ref`、`certainty`	史料位置与判断可信度	区分已见于史料的关系和研究推断

【建议优先掌握：如何判断是否需要 Gephi】如果你的主要问题只是“这些文书从哪些人流向哪些机构”，而节点很少，手工关系图可以是合理输出；如果你希望**系统性比较中介者、关系密度或群组差异**，或者希望让程序在较多记录中发现不明显的结构，Gephi 及类似工具的分析功能才更关键。若要回答“沿什么路径、跨越哪些空间”，应再考虑地理可视化，而非指望 Gephi 一张图承担所有问题。

2.10 自动化采集历史资料的研究伦理：技术可行不等于许可

定位：1:08:30–1:11:46；1:13:57 左右之后进入短暂休息。

【课堂内容】一位同学分享自己使用 AI agent 对 `NewspaperSG` 类数字报刊资料执行 OCR 或批量处理，担心可能违反网站服务条款（terms of use）。老师从两个层面讨论：服务条款是用户已同意的规则；从研究伦理角度，也可以问自动化抓取是否损害他人访问、是否给网站服务器造成过大负担，以及处理结果是否用于商业转售。课堂讨论提到教学/非商业研究目的与对服务器资源的顾虑。

必须区分：老师讨论“使用条款背后的意图”和实际损害，**并不等于授予违反网站条款的许可**，也不构成版权或计算机访问法律意见。老师没有在转写中给出可以通用于所有网站的合法抓取标准。

【补充解释】开展这类项目时，更可靠的步骤是先查看网站的许可、访问条件和 API / 批量下载方式；必要时咨询馆藏方；尊重速率限制、隐私、权利声明，避免高并发采集。能在本地运行程序，也不自动改变原网站对数据获取的限制。

2.11 众包（crowdsourcing）：把巨量材料分解为公众能够可靠完成的小任务

定位：1:17:18–1:46:01；中间有平台演示和同学问答。

（1）什么是众包，为什么数字史会采用?

【课堂内容】老师让同学定义 **crowdsourcing**：把一项研究工作中的特定任务交给团队以外的人、尤其是公众志愿者完成，从而利用多人共同投入的时间、知识和判断。众包可能收集社区经验、地方记忆或感知；这些材料即使与客观物理事实并不完全一致，仍然可能有助于研究**某个社群如何认识自己的居住空间**。因此须先区分：研究者究竟要核对客观存在的物件，还是要研究共享记忆和想象?

本节重点是更具体的一种：**请志愿者帮助整理、识别或转录历史史料**。例子涉及气象/船舶日志、自然历史记录、手写文书乃至中世纪手稿。即使现代 OCR 很有用，碰到字迹不清、扫描模糊、表格复杂和符号特殊的材料，仍可能把 `4` 看成 `8`；志愿者可以动用语境判断去处理机器辨识困难的部分。

（2）人工作业怎样设计，才适合众包?

老师反复强调三个特点：**任务小（small）、说明明确（clear）、可以重复（repeatable）**。一页文献若包含页边注、下划线、箭头、括号，研究团队必须提前规定转录符号：箭头从哪一行指向哪一行如何标示？不确定文字如何输入？原文里的日期以什么标准转换？避免不同志愿者各自发明标记法，导致结果难以合并。

众包项目通常需要 **field guide / transcription guide（字段或转录指南）**、示例、常见问题和团队答疑空间。老师提到在线社区论坛：当志愿者遇到说明没覆盖的情形，项目成员必须回应，并据此更新规则。最好把工作切成几行、一条记录、一幅图像等小单元，志愿者完成几分钟即可暂停，下次继续，而不是必须一次掌握整份史料背景。

设计原则	为什么重要	课堂例子对应的落实方式
单元很小	降低加入门槛与中途放弃损失	一行表格、几行手稿、一次图像识别
说明明确	不同人交付的结果才可比较	箭头、下划线、边注、日期的统一标记
任务重复	志愿者熟悉格式后效率提高	同一种表格反复抄录，不频繁更换任务类型
项目团队在场	必然出现说明外的例外	论坛问答、更新指南、处理争议
结果可核验	人也会犯错	多人交叉转录与一致性判断

（3）正确性怎么保证：重复转录与交叉核对

同学问，志愿者的答案如何验证？老师给出的课堂示例是：**同一张图像分派给三个人进行独立处理，至少两人的答案一致，才进入数据集**。因此如果有 1000 张待转录图像，就会产生约 3000 次转录任务。这种设计能够发现部分偶发错误，但它需要更多志愿者时间，也不能保证多数人不会共同误读同一难字。

【补充解释】对没有两票一致、或者存在专有名词/复杂符号的条目，实际研究可以建立“争议队列”交给研究团队复核，并保留原始图像与志愿者提交版本。此队列是通用质量控制建议，**不是老师在课堂上明确列出的操作程序**。

（4）如何吸引志愿者并让项目持续运作

老师演示的平台根据上下文应为 **Zooniverse**（转写出现 “universe” 等错误）。平台承载不同研究团队发布的分类、标注和转录任务。老师举过天文影像对比、野生动物相机图片识别等非历史学例子，说明同一逻辑适用于多学科：把海量资料转化为一个个简单的“有/没有” “这是什么”或“请抄写”的判断。

老师引用了一个**数量级式的课堂说法**：约 **1% 的高度活跃志愿者完成 90% 以上的工作**，许多人只是试做一页或两页。应把它理解为课堂对贡献高度不均衡现象的强调，**不能在缺乏原始研究文献时作为放诸所有众包项目的精确统计常数**。

为留下志愿者，研究团队可以：展示完成进度；按批次设置里程碑；表扬高贡献者；定期向志愿者报告他们的劳动发现了什么；通过本地历史社团、气象/航海社群、学生团体和媒体宣传触达可能感兴趣的人；组织固定的共同标注活动。老师特别强调，**项目团队与志愿者之间的持续沟通至关重要**。它不只是科研技术，也包含公共沟通与社群管理（community management）的工作。

经济性问题：众包不是“免费研究劳动力”。即使平台免费，项目仍需设计规范、招募、培训、答疑、质检、维护、反馈、处理伦理问题。老师提醒：没有充分规划，不应指望临时上线一个项目就获得稳定、大规模的贡献。

（5）人工标注与机器学习：何处衔接?

【课堂内容】老师说明，经过人工核验的标注可作为 **ground truth（参考真值/标注基准）**，用于训练机器学习模型；例如志愿者先确认部分图像里有哪种动物，之后再让计算机学习识别大量其他图像。这与此前课堂讨论的**监督学习（supervised learning）**相连。

老师也提到三维物体与空间数据通常比纯文本数字化更复杂，扫描、标注成本更高，不同形态数据未必已经有足够规模的训练样本。与技术有关的时间预测属于课堂上的估计，不应在笔记里直接当作行业定论。

【补充解释】“用人工标注训练算法”不等于必然用于**生成式人工智能（generative AI）**。分类模型、识别模型、图像处理与生成模型可能采取不同技术路径。老师针对旧式自动图像上色和营销中的“AI”标签提出区分，重点是不要把一切计算方法混称为生成式 AI；现代部分上色技术也可能真的采用机器学习，因此不能从“上色”二字判定其技术原理。

（6）贡献者同意与再利用伦理

有同学提出：如果志愿者原本只是帮助转录，却发现劳动成果被用于训练模型，他们是否应该事先知情？老师认可这一问题，指出项目设计之初就应清楚说明贡献的**用途、共享与后续再利用**，尽可能取得同意（consent）；如果后来才打算增加新的用途，需要根据项目情形再通知参与者并处理是否参与/退出的选择。课堂中“opt in / opt out”转写有混淆，准确机制须进一步查看项目规范。

综合理解：众包项目从不是“把原始图片放上网等人来做”。它是一条完整的研究流程：

确定史料与问题 → 划分微任务 → 制定转录指南 → 招募与沟通 → 多人独立作业 → 质量检查 → 整理数据 → 说明使用范围 → 反馈研究成果

2.12 媒体保存：消失的不只是节目，还可能是“观看节目时的体验”

定位：1:46:01–2:21:19。1:47 起长时间播放第三方纪录片，以下专门区分片中讲述与老师的评论。

（1）纪录片在调查什么?

【课堂内容／老师导入，约 1:47:48–1:49:08】老师播放一部约 90 分钟的纪录片的若干片段。纪录片制作者追查**迪士尼频道一段标志性的四个音符短旋律是谁创作的，以及它何时开始出现**。看似很小的流行文化问题，实际上需要反复寻找早年的节目间隙录影、字幕/标识变化、网络存档、制作者线索与相关人员证言，过程类似历史研究中的史料追索。

【纪录片内容，约 1:49–2:08】制作者特别关注电视台节目之间的短促内容：**频道识别片（network identification）**、**过场包装（bumper）**、**节目间插播内容（interstitial programming）**。这些内容告诉观众“这是哪个频道”“前一个节目是什么”“接下来是什么”，也塑造整套观看经验。一个人今天在 DVD 或流媒体上看到某一集节目，通常看不到当年电视直播时的频道包装和节目过渡。因此同一节目并不一定能重现当年的**观看语境（viewing context）**。

纪录片示范了史学研究常见的困难：二手资料对迪士尼频道更新设计的日期可能有矛盾，研究者必须找有明确年代的录影片段比对；一些素材靠普通观众保存旧电视录影并上传网络才得以存留；有关幕后制作的文件和视频可能散落在网络文章、已删除的播放列表、公司作品集与个人记忆中。课堂播放的片段里出现过 2002 年 9 月底与 10 月初的相互冲突日期，**不要在没有核对纪录片全文与原始证据前写成确切首播日**。

片中还讨论，许多被认为只是商业委托或“次要”创作的短旋律和频道片头，仍可能与数百万观众的记忆与情感相连。老师利用这一点追问：谁有权决定什么算值得保存的文化成果?

（2）老师从纪录片提出的四组史学问题

A. 完整的历史语境与档案的选择性留存（约 2:08:10–2:10:16）。影片正片可能被保留，但节目之间的小片段、广告、过场、频道标识等可能没有进入正式机构的档案。仅保存“作品”而失去其当时播出的组合，历史学家就可能无法重建真实观看体验。私人录像者、影迷和非正式网络社群于是成为**非正式档案（informal / fan-run archives）**的重要保存者。

B. 使用权、版权与私人收藏（约 2:10:16–2:13:02）。私人留存电视节目、公开上传片段、研究者重新利用商业素材，并不属于同一个法律问题。老师提醒版权例外、合理使用（fair use）和私人录制的规则可能依司法管辖区不同而不同；课堂没有给出一条能全球适用的规则。因此要区别“有人在网上提供”与“研究者当然可任意复制传播”。

C. 法律允许并不自动代表伦理适当（约 2:13:02–2:14:03）。纪录片提到某些幕后花絮（outtakes / behind-the-scenes footage）不是为了公开播出而拍摄，却在多年后流出或被公司放出。老师用这一点对比此前对网络论坛资料的讨论：即使内容技术上可以被访问，原参与者发布时可能并不预期被广泛传播。研究时需考虑原始情境、期待隐私、二次传播的可能伤害、资料价值与再利用边界。

D. 保存价值会随时代改变（约 2:14:03–2:17:05）。过去的报纸、廉价印刷品和宣传册可能被当作一次性读物；电视曾被视为低于电影的艺术形式，后来又成为文化史材料。今天的短视频、社交平台帖文、聊天频

道、平台评论等，或许也会成为未来研究的重要证据。资料的“短命”和“平凡”不能用来证明它没有史学价值。老师借此引导大家思考：谁决定保存什么、有什么资源可保存、哪些资料被制度性忽视?

（3）数字材料面临哪些特殊的保存风险?

定位：约 2:11:29–2:12:18、2:17:06–2:19:21。

- **格式与版本差异**：电视从约 4:3 画面转向 16:9 宽屏/高清，同一历史时期可能同时存在不同播出版本。只存一个版本，可能抹去部分用户曾看到的画面构图；研究者需要明确保存的是哪一个版本与技术条件。
- **平台许可与持有并非同一回事**：订阅流媒体通常意味着期限和地区受控的访问，不等于永久拥有媒介；平台因授权到期下架内容，就可能让普通用户无法继续接触它。与之对照，实体光盘可留存，但仍受设备、介质寿命等条件制约。
- **软件与电子游戏的可执行性**：老游戏可能因操作系统和硬件改变而难以运行；模拟器（emulator）等技术尝试保存其可玩性，而不是只保存截图或文件名。
- **元数据与存储方式**：数字资料不能只把字节保存下来，还需保留足以理解来源、格式、版本和再现条件的元数据。老师在结束时提到**用合成 DNA 存储信息**等新技术设想，用它提示存储媒介可能持续变化；这不是本课已验证的实际档案保存方案。

【补充解释】媒体保存至少有三个层次：**文件存在（bit preservation）**、**还能被打开或运行（technical usability）**、**还能理解其产生和使用的社会语境（contextual intelligibility）**。课堂没有用这个三分法作为正式模型，但它能把老师关于录影、游戏、平台下架与节目过场的讨论联系起来。

（4）课程结尾与下周衔接

定位：2:19:36–2:20:58。

老师总结：数字项目出现数据缺失、软件难用、研究范围过大、问题必须调整等困难是常态；与其他研究者交流过程很重要。结尾预告下一周进入**storytelling / narratives（叙事呈现）**相关内容，即将复杂历史研究与文字、多媒体、数据、地图等结合，以公共历史的方式组织和呈现给观众。具体课程安排还应以课程平台的下周通知为准。

三、知识关系与重点对比

3.1 本节课最重要的逻辑链：方法、项目与伦理是一体的

这节课不应被理解为一串互不相干的工具介绍。老师的所有讨论，都在回答数字史研究中同一个问题：**如何把不完整、不规范、存在偏向的历史材料，转化为别人可以检查、理解和使用的研究成果?**

第一层：知识如何形成。 数据整理与分类本身已经包含解释选择；可视化进一步决定观众会看见什么。森林分类的例子说明“数据如何编码”可能参与社会权力和价值判断。

第二层：技术怎样协助研究。 Gephi、数据库、OCR、地图与时间轴都只是在不同问题下发挥功能。选择工具应先决定“要解释空间移动、时间变化、群体结构还是类别差异”；再考虑数据是否足以支撑。

第三层：怎样确保别人能够审查。 保存原始证据与处理说明、记录工具版本、公开适当范围内的数据，能够让别人追踪结果。众包研究进一步把核查责任分配给多个参与者，但也增加协作规范和研究伦理需求。

第四层：研究如何成为公共历史。 研究者必须思考成果对哪些公众有意义，怎样组织非专业志愿者，如何通过展示向资助者说明未来可能性。媒体保存提醒我们，档案本身来自机构与公众有选择的保存实践。

在哪个阶段?	研究者需要回答	与本节课哪个主题有关?
史料入手	哪些记录可用？缺了什么?	档案编目、数字媒体佚失、历史地名
数据构建	定义哪些实体和关系？如何分类?	curation、数据清理、家庭档案数据库
分析与探索	哪个工具适合回答问题?	Gephi、地图、时间轴、中心性
验证与共享	别人如何检查我的处理过程?	README、版本、众包重复转录
解释与沟通	哪些历史发现重要？如何向公众表达?	误导性可视化、pitch、storytelling
伦理与保存	谁有权使用材料？谁决定保留什么?	网站条款、志愿者同意、版权、影迷档案

3.2 最容易混淆的概念对照

对比	核心区别	什么时候需要区分?
探索性可视化 / 展示性可视化	前者帮助研究者在分析中发现模式；后者面向他人清楚呈现经解释的发现	你不知道网络整体形状时，与期末发布一张成图时
度中心性 / 特征向量中心性	前者重连接数；后者还重连接对象的重要程度	“认识很多人”和“认识重要的人”可能给出不同结论
中介中心性 / 特征向量中心性	前者强调桥梁及最短路径；后者强调重要节点间的连接关系	判断跨群体中介与核心权力圈成员时
数据清理 / 史料解释	清理使字段可比较；解释要判断一条记载在其历史语境中意味着什么	统一人名拼写与判断是否同一历史人物时
网络图 / 地图	前者强调关系结构，后者强调地理位置、距离与空间迁移	敦煌写本的收藏关系与流散路线
期末 pitch / 反思 essay	前者展示可行性与未来潜力，后者交代实践过程及方法反思	选材、详略、失败经验应分别放到哪里
众包 / 单纯公开网站	众包要求公众实际承担分类、转录等研究任务；公开网站只提供查阅不一定有协作	设计家庭档案公众参与方案时
平台可访问 / 资料可合法再利用	资料能被看见，不表示能被自动抓取、再发布或训练模型	报刊数据库、社交媒体帖文、电视节目片段
文件保存 / 历史体验重建	保留某一集节目不等于保留当年广告、过场、画面格式和观看方式	研究电视、视频网站和电子游戏时

3.3 一个贯穿全课的案例分析：从敦煌史料到可解释的数字史成果

【补充解释／应用演示，**不是课堂实际完成的项目数据**】假设研究的是“某一批敦煌写本为何先后进入不同机构”。应先列出能由史料支持的节点（人物、机构、地点）及边（持有、交易、转交），保留争议与不确定性；再问自己需要哪一种证据：如果关注中介人物，网络分析可能合适；如果关注从敦煌向海外的路线，应考虑地理与时间数据；如果只是向公众说明一条较简单的流通链，人工示意图也可能更清楚。最后在图注标明数据边界，不能把未证实的转手关系画成已证实的事件。

请注意：**一个网络中的“重要节点”不是自动得出的历史结论。** 它只表明这个节点在你所定义的、由现存材料构成的网络里有某种结构位置。要进一步说“控制了敦煌文书的流散”，仍需交易记录、档案、通信、时间先后等历史证据支持。

四、复习速查

4.1 必须理解的核心结论

1. **数据集与可视化都经过选择和整理**；所谓“客观数据”仍须追问收集与分类方式。（01:28–02:35）
2. **先提出要解释的历史问题，再选择可视化形式**；探索性作图还可以反过来发现新问题。（02:42–05:16）
3. **网络中心性的含义不是一个“排名”**：degree 看直接联系，betweenness 看桥梁位置，eigenvector 看连接对象的重要性。（05:21–11:01）
4. **数值必须在网络、方法与史料语境中解释**；不同指标高低不一致很正常。（05:34–10:30）
5. **脏数据并非全能靠一条规则修好**；历史身份、时间、地名的变化尤其需要判断。（11:10–13:06；50:26–1:01:04）
6. **研究可复现性来自数据、处理步骤、选择依据和软件版本的透明记录**。（13:06–17:04）
7. **图表即使印了正确数字也可能误导**；要检查面积、比例、刻度、方向与分类。（17:05–24:27）
8. **一个能工作的原型胜于未完成的宏大设想**；展示证明可行性，反思论文解释过程。（27:43–31:48；43:54–49:34）
9. **Gephi 并非强制工具**；它有利于探索复杂网络和计算指标，但手工图有时更符合研究任务。（1:01:44–1:07:23）
10. **众包的核心难题是研究管理，不只是召集更多人**；小任务、清晰指南、冗余核查、定期反馈缺一不可。（1:17:18–1:46:01）
11. **公众贡献的再利用必须考虑告知与同意**，网络数据采集也必须尊重权利和使用条件。（1:08:30–1:11:46；1:41:20–1:43:09）
12. **数字史保存的是带有语境的媒介经验，而不只是几个电子文件**；“小而短暂”的媒体也可能是未来的重要史料。（2:08:10–2:18:22）

4.2 最容易遗漏的限制和条件

- **“数字越高”只能在同一度量方式可比较的前提下讨论**。不同网络规模、权重与算法归一化可能让数字不可直接比。

- **地名和行政/日常空间不是跨时代固定容器**。现代地图坐标不应随意套给过去的同名区域。
- **日期输入软件能识别，不等于历史日期本身精确**。若材料只有“约某年”，不要擅自补出某月某日。
- **两人转录一致不等于绝对正确**，但比只靠一次人工录入多了一层核验。
- **众包的高活跃者贡献不均是课堂经验概述**，不是所有项目必然精确符合“1% / 90%”。
- **“学术价值”“社会影响”和“商业盈利”不可混为一谈**。项目争取资助时要看征集要求。
- **技术可做、网站可打开、有人分享，不等于自动得到访问/版权/再利用许可**。
- **本节课使用的图表、网站和纪录片原片并未完整随材料提供**，遇到需要具体数据的例子，须回看课件或视频。

4.3 老师明确提及的课堂作业/安排与建议复习点

【老师明确提及的考核/提交要求】：Week 11、Week 12 是项目展示周；在课堂口头讨论中展示约 5–6 分钟，需聚焦；可发邮件表达想在哪一周展示；合作项目的 presentation 可合作，但反思 essay 应写个人经历和观点。**具体安排以最新课程公告为准**。（28:14–31:48）

【建议优先掌握】：准备给老师解释自己项目时，尤其练习如下四句：①“我的研究问题是……”；②“我的数据字段、分类与排除依据是……”；③“我采用/不采用 Gephi，是因为我需要回答……”；④“我已经做出了什么可验证的原型，下一步准备怎样扩展……”。这四句是根据课堂反复出现的研究逻辑归纳的复习建议，**不是老师宣布的考试题**。

五、自测题与参考答案

使用方法：先只看 5.1 的十二道题，尽量口头回答并说明证据来自本课哪一部分；再翻到后面的 5.2 核对。题中凡是研究者新设计的情境，均标为【练习题】，不把它当作老师课堂原例。

5.1 自测题（先独立完成）

问题 1｜概念理解。 为什么老师说“数据集本身已经经过 curation”？它与数据可视化的客观性有什么关系？

问题 2｜方法匹配【练习题】。 你有一批 1930—1950 年的旧报刊记录，想比较每年讨论“药物剂量”的文章数量。你优先选择什么形式？若想比较不同药铺的联系，形式会如何变化？

问题 3｜比较辨析。 degree、betweenness、eigenvector centrality 分别试图测量什么？一个“连接数少但认识关键人物”的节点可能怎样表现？

问题 4｜数值解释【练习题】。 某人物的 betweenness centrality 为 0.42。是否能直接得出“他是当时所有商人中的主要权力中介”？需要哪些额外条件与证据？

问题 5｜数据清理。 电影标题前都多了相同前缀，与同一个地名在旧地图、当代地图位置不同，为什么属于两种性质不同的清理问题？

问题 6｜研究透明性。 你看到一张没有 README 的历史地理分布图，要试着重建它，至少需要追查哪些内容？为什么应记录软件版本？

问题 7｜识别误导【练习题】。 一张图标出数值“56”和“44”，却把 56 画成更小份额。另一张图数值无错，却用向下箭头表现价格上涨。这两张图分别存在什么误导？

问题 8｜课程产出。 你做一个数据库项目，目前只完成少量文件的样本导入及可运行原型，尚未建公众网站。期末 pitch 和反思 essay 应分别讲什么？

问题 9｜敦煌应用【练习题】。 一份数据有 12 个敦煌文书收藏机构和几条明确的转交关系；你只想向非专业观众解释已知的流散过程。是否一定要用 Gephi？如果增加到上百个人物和机构并要比较中介者，答案会如何改变？

问题 10｜众包工作流。 为什么众包项目必须将任务设计为可重复的小单元，并配备清楚指南？老师介绍的“三人转录、两人同意”机制是如何运作的？

问题 11｜伦理判断【练习题】。 一个志愿者平台最初承诺只将手稿转录用于开放历史数据库，后来想把转录文本用于模型训练。研究团队应考虑哪些事？为什么“非商业研究”也不能直接替代许可？

问题 12｜保存与历史解释。 研究一档 2002 年的电视节目时，为什么只找到节目正片还不够？如果现存录影只来自个人收藏或粉丝上传，历史学家需要考虑哪些证据与伦理问题？

5.2 参考答案与简要解析

答案 1。 数据集制作需要选取史料、定义字段、合并实体、标注关系与处理不确定性。研究者在这个阶段就影响了将来能出现什么结论，因此不能把“原始数据”假设成没有观点的事实，进而把可视化看作唯一会加入解释的环节。要公开解释性决策及其依据。**对应：2.1。**

答案 2。 按年份比较数量适合时间轴或折线图；若是在特定离散年份之间比较数量，也可以使用条形图。药铺间的联系则应考虑网络图，但要先定义“联系”是交易、人员、共同持有还是其他关系。**对应：2.2；为新设练习情境。**

答案 3。 度中心性看直接连接多少节点；中介中心性看是否位于许多其他节点最短路径之间；特征向量中心性看连接对象的重要程度。认识关键人物但联系总数不多者，可能 degree 偏低、eigenvector 较高；其 betweenness 并不一定高。**对应：2.3。**

答案 4。 不能直接得出。首先应核对网络构造：纳入哪些商人、使用哪些来源、边代表什么、统计范围为何；其次应知道 0.42 的算法与归一化以及同一网络其他节点的数值；最后须由交易、通信、组织和时代背景等史料解释“中介”是否真的代表权力。**对应：2.3。**

答案 5。 标题固定前缀是可定义规则的大规模格式清理；历史地名迁移涉及对象定义、史料时间和社群空间认同，不能按拼写相同就假设同一坐标。后一问题可能从“数据麻烦”变成真正的研究发现。**对应：2.4、2.8。**

答案 6。 至少追查原始数据来源、字段含义、时间/地理范围、纳入与排除、处理步骤、制图投影或布局方法、图例和计算设置。软件版本可能改变默认行为、算法或显示方式，从而影响可重复性。**对应：2.4。**

答案 7。 第一张图在视觉份额上违背数值大小；第二张图通过符号方向暗示与真实涨跌相反的结论。二者说明“标注数字正确”并不保证视觉叙述忠实。**对应：2.5；为新设练习情境。**

答案 8。 pitch 突出样本系统已经如何运行、当前发现、公众价值与未来扩展方案；essay 解释元数据为什么这样设计、为何采取该软件、遇到哪些录入和前端衔接问题、什么方法失败以及后来怎样调整。原型比漫无边际承诺更有说服力。**对应：2.6、2.8。**

答案 9。 不一定要用 Gephi，12 个节点可采用手工关系图，重点是准确清楚并标注证据。若记录扩展到上百个节点、需要探索社群或计算中心性，则使用 Gephi 或其他网络分析工具的理由更充分；同时仍要考虑时间和空间信息。**对应：2.9；为新设练习情境。**

答案 10。 小而重复的任务降低门槛，让结果标准化并便于持续参与；指南用于处理边注、箭头、括号、日期等特殊写法。课堂示例中每件资料由三位志愿者独立处理，若至少两人结果一致，便可视为达到所举的验证门槛，但多数一致也不绝对保证正确。**对应：2.11。**

答案 11。 应重新审视最初告知与同意范围，说明模型训练用途、是否公开共享、会否给贡献者及史料权利人带来风险，并视情形取得新的选择或同意。非商业不一定等于被授权采集、复制、发布或训练。**对应：2.10、2.11；为新设练习情境。**

答案 12。 节目间包装、频道标识、广告、原始宽高比和节目编排会影响当年的观看体验；仅有正片会损失历史语境。粉丝录影提供珍贵证据，但研究者应核实年代与版本、注明来源、考虑数字文件完整性及版权/隐私/未经预期公开的材料再利用伦理。**对应：2.12。**

六、待核对与缺失信息

6.1 本次整理的证据边界

本次已完整提取并阅读了 156 页 PDF 的英文转写（时间段覆盖约 00:00—02:21:19），并对 WAV 原始文件做了可读性、时长和多个时点的音频信号检查；**没有完成词语级的原声听辨**。因此以下修正都属于**“依据转写上下文进行的高概率规范化”，不是“听到老师原话后确定的纠正”**。此处特意集中披露，避免将推断写作录音核实结果。

位置	原转写中的问题	本笔记处理及依据	后续处理
05:21–10:30	`Turkey`, `notes`, `between us`, `igen vector`, `icon vector`	结合连续讨论网络分析，分别按 Gephi / nodes / betweenness / eigenvector 理解；不把机翻“土耳其、音符”当专业概念	建议对音频作术语级复核
12:37–12:51	`Urban Refine`	按知名本地开源清理软件推定为 **OpenRefine**	【待核对】具体念法及是否指此软件
15:53–16:20	`Gaffy` 和算法版本	结合前后明确讨论按 **Gephi** 处理	【待核对】具体版本或示例算法名
17:05–22:12	糟糕图表中的品牌、人名、数值、上下箭头	保留可证实的误导机制，不还原未见图表	【缺失】原始幻灯片、图像与图注

位置	原转写中的问题	本笔记处理及依据	后续处理
27:43–28:57	建筑/地点转写成 `book key` 等	只概括为“建筑保护的 3D 原型”，不强行断言具体建筑群名称	【待核对】项目地名
31:51–40:51	`SSHRC` 及外国基金机构名称、博物馆项目等	记录研究资助逻辑，不把机构缩写和项目结果当已核实事实	【待核对】机构官网及老师展示资料
50:26–1:01:04	旧地名反复转写为 `Tractor Con / truck to come` 等	不给出确定拼写或历史边界，集中讲地名、地理与归档的史学问题	【待核对】旧地图、地名和水库名称
1:01:44–1:08:30	`JFE`, `Jerry`, `Gaffy`, `Demon Project`, 日期示例有错词	按上下文是 **Gephi** 与**敦煌 / Cave 17** 问答；将“必须用 Gephi”的疑问与老师答案清楚保留	【待核对】个别专名与日期细节
1:17:18–1:46:01	`cross sourcing`, `universe`, `few guide`, `ground truth` 混乱	统一按 crowdsourcing、Zooniverse、field guide、ground truth 的上下文含义呈现	建议音频/课件复核演示平台和任务名称
1:47:00–2:08:00	大段英文为纪录片录音，语音识别出现人名与日期错配	严格区分第三方纪录片讲述与老师讨论；不将结尾所述线索写成确定创作者姓名	【缺失】纪录片原视频与影片内截图
2:20:24–2:20:58	下一周主题识别成 `screwly telling and Americans`	据紧邻对 narrative、text、multimedia、maps 的描述，概括为 storytelling / narratives	【待核对】课程公告中的正式主题名

6.2 缺少的重要课件或可视证据

1. **前一周的可视化网站链接和相关讲义**：老师在约 04:15–04:36 提及，但转写未保留网址。没有网站就无法核实其示例或复习课堂投影中的选择图表方法。
2. **约 17:05–22:12 的误导性图表**：转写只有对图的口头指认，缺少图片，故不得推断精确图面、全部百分比和图例。
3. **同学项目展示的数据库界面、旧地图、敦煌网络图、Gephi 操作画面**：老师可能指向屏幕或地图，但只凭转写无法恢复坐标、字段及网络布局。
4. **众包平台演示画面及具体项目说明**：文本足以整理设计原则，但无法逐页还原模板、屏幕上的按钮或实际字段。
5. **纪录片全文、录影画面和相关网页归档**：本笔记只整理课堂实际播放与讨论的部分，不替代观看完整影片。
6. **期末展示安排的正式公告和评分细则**：老师在课上谈及 5–6 分钟、Weeks 11–12 和个人论文的性质；如后续有新通知，应以最新课程要求为准。

6.3 仍值得主动追问老师的三个问题

- **关于敦煌项目**：如果最终只能可靠建立几十条文书转手关系，但部分年代不确定，那么课程项目更看重网络指标的计算，还是对数据组织与历史解释边界的说明？（由 1:01:44–1:08:30 的讨论自然引申；不是老师原话。）
- **关于可复现性**：如果因史料版权、隐私或平台条款无法公开原始数据，报告中应至少公开哪些字段说明、匿名汇总、代码或方法记录？（由 01:49–02:35 和 13:06–17:04 引申。）
- **关于媒体保存**：在机构正式档案、粉丝私人保存和平台持续下架之间，历史研究应怎样建立来源链、评估版本的可靠性与遵守使用规范？（由 2:08:10–2:18:22 引申。）

资料出处：用户上传的《数字历史项目讨论：可视化、数据清理、众包与媒体保存》双语转写　　PDF（156 页，含每段时间戳）及同名 WAV 录音。讲义、幻灯片和完整纪录片未包含在本次材料中。本笔记为理解和复习用途，不是逐字会议记录，也不应取代课程正式评分公告。